Confessions de crameurs de GPU

Mardi 10 Mars 2026

Grégoire et Quentin

Elastic rencontre-haute

elastic | The Search AI Company

Agenda

01	Intro Greg
02	How to get into leaderboard Quentin
03	Architectural tips for MTEB Quentin
04	Cost of training

Qui sommes-nous ?

Grégoire & Quentin 🇫🇷

- Membres de l'équipe **Jina @ Elastic**
- 21 spécialistes Machine Learning
- Distribués sur 3 continents

"Entraîner des modèles de pointe pour la compréhension du langage naturel."

4 FAMILLES DE MODÈLES

Dense embeddings

Rerankers

Optimisation de la pertinence et classement de haute précision.

Sparse Embeddings

Représentation sparse apprise (ELSER)

Reader LM

Modèles génératifs pour la transformation HTML → mkdown

Qui sommes-nous ?

Grégoire & Quentin 🇫🇷

- Membres de l'équipe **Jina @ Elastic**
- 21 spécialistes Machine Learning
- Distribués sur 3 continents

"Entraîner des modèles de pointe pour la compréhension du langage naturel."

4 FAMILLES DE MODÈLES

Dense embeddings

jina-embedding-v5-text-nano
jina-embedding-v5-text-small

jina-clip-v2
jina-vlm-1

Rerankers

Jina-reranker-v3 (Octobre 2025)

Elastic-rerank (Mars 2025)

Sparse Embeddings

Elser-v2 (Octobre 2023)

Reader LM

readerLM-v2

jina-v5-text

Jina API

Elastic Inference Service

Hugging Face 🤗

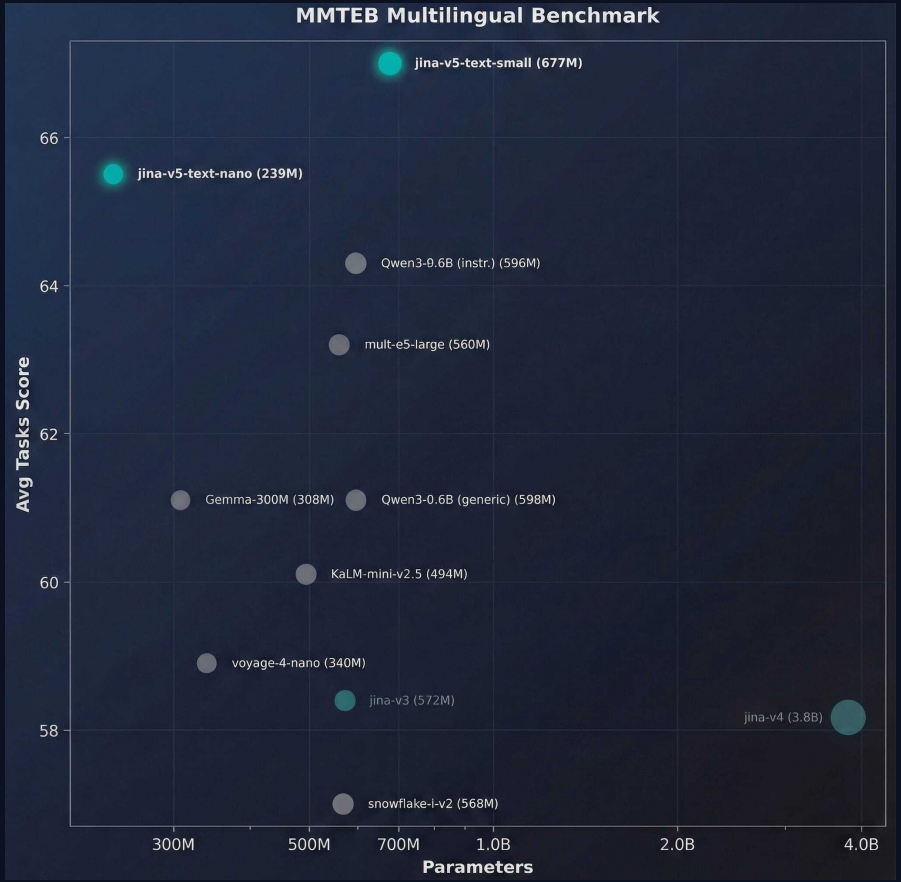

Le leaderboard

MTEB

Massive Text Embedding Benchmark

English only

Open datasets

MMTEB

Massive Multilingual Text Embedding Benchmark

Multilingual

Open datasets

RTEB

Retrieval Text Embedding Benchmark

Multilingual

Closed datasets

elastic

La colonne vertébrale matricielle

EuroBERT 210M

Modèle de base structuré

~8k €

Qwen3 0.6B

Architecture massive

~180k €

Les datasets

- Open public datasets
- Cleaning, filtering, mining
- Synthetic generation

Pre-training

Un milieu chaotique

L'environnement initial d'entraînement non structuré et complexe.

Origine énigmatique

L'origine des données utilisées est parfois difficile à tracer ou à définir.

Zero-shot?

La définition même des capacités zero-shot reste souvent floue.

Typologies

Unified Embeddings

LoRA Adapters

Prefixes

Combien coûtent ces modèles ?

Le coût d'EuroBERT 210M

200 000 heures GPU budget total (source), 5T tokens

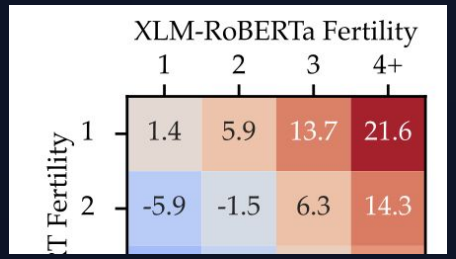

Entraînement

Le budget proportionnel linéairement au nombre de paramètres: 210M + 610M + 2000M = 2800M.

- **210M = 7.5%** des 3 modèles
- **15 000** heures GPU

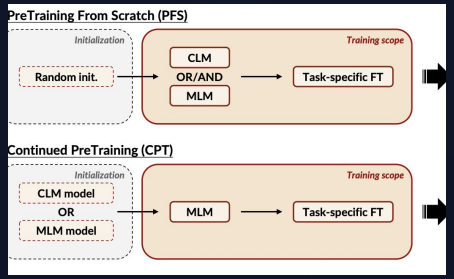

En comptant la R&D

Le travail nécessaire pour trouver l'archi finale. Non linéaire avec le nb de paramètres

- **110 000** GPU heures englouties
  R&D : 110 000 / 3 = 36 500
- **Training 7.5%∗ 90 000 = 6 000**
  210M = 42 000 heures GPU

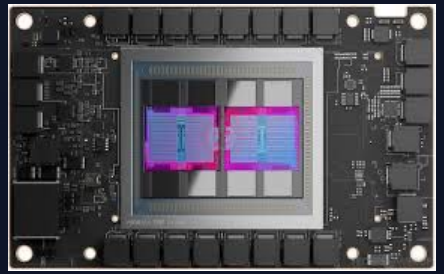

Cout en ressources

42 000 heures GPU à 625W sur Adastra (PUE 1.1), node peak at 2670W

- 2670 / 4 ∗ 42 000 = **31 000 kWh**
- 31 000 kWh * 30.2= **931** kgCO2eq
- 31 000 kWh * 0.86 = **26 521 L**
- 42 000 ∗ 2€/h = **80 000€**

Le coût de Qwen 0.6B

~300 000 heures GPU budget pour 0.6B, 36T tokens

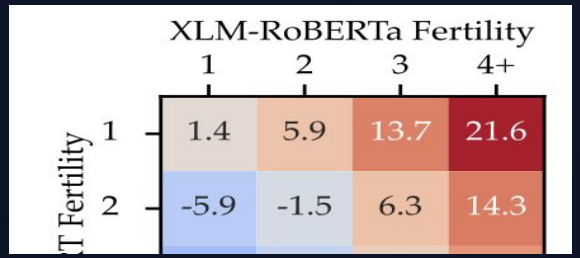

Entraînement

estimation sur cluster H800

90 000 GPU heures pour l'entraînement

210 000 GPU heures / 8 Modèles

26 000heures GPU de R&D / modèle

116 000 Heures budget total pour 0.6B

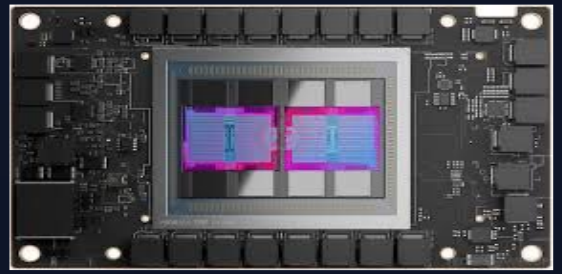

Cout en ressources

116 000 heures GPU à 700W sur Ali DataCenter (PUE 1.2), 8 node gpu DGX H800 peak à 10200W

10200 / 8 ∗ 116 000 = **147 900 kWh**

150 000 ∗ 0.44 ∗ 375g = **24 500** kgCO2eq

150 000 kWh * 4.7 = **750 000 L**

116 000 h * 2€/h = **230 000€**

Le coût de jina-embedding-v5-text

Vu la taille des datasets, on estimerait 15 000 heures GPU

SKU	Service	SKU ID	Usage	U
Nvidia H100 80GB GPU attached to DWS Defined Duration VMs running in Americas	Compute Engine	341A-49A5-0C07	39,261.8 hour	

Estimation vs réalité

H100 sur GCP + Cluster acheté de 3×8xH100

Les mesures donnent 50 000 heures GPU

40 000 sur GCP, 10 000 sur notre cluster

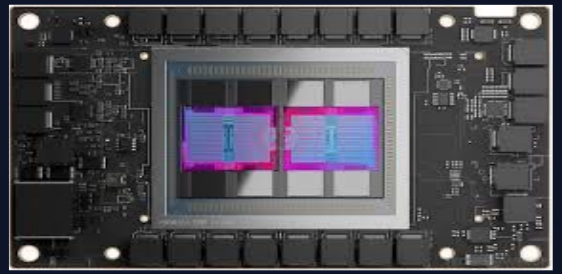

Cout en ressources

50k GPU à 1000W (8xH100)

55 MWh (43 in us-east, 12 in Sweden)

20 000 CO2kgeq (19.6 in US, 0.2 in Sweden)

220 000L (183kL US, 36kL Sweden)

200 000$

Conclusion

Merci pour votre attention

Des questions ?

Sources:

- Study on Impact of Electricity Production on Regional Water resource in China by Water Footprint"
- Jina v5 tech paper
- Qwen3
- EuroBERT 1 and prelim study
- ACV approach for LLM footprint

elastic